



MEMORIA CACHE DEL CPU



Atilano Velázquez Leonardo
Valdez Subirachs Sebastián

THE MEMORY WALL



¿De donde viene la
memoria caché?


Al avanzar la velocidad de los procesadores (CPUs) la memoria
nunca avanzó a la par

Procesadores y tarjetas graficas

- Puntos negros = transistores en CPU
- Puntos amarillos = transistores en GPU

Memoria

- Puntos rojos = memoria RAM DDRX (Desktop)
- Puntos naranjas = memoria RAM LPDDR (Laptops)
- Puntos azules = memoria RAM HBMX (Servers / IA)




Source Arteris/NVIDIA and "Fast validation of DRAM protocols with Timed Petri Nets," M. Jung et. al, MEMSYS 2019

Memory Wall

Podemos ver que la cantidad de transistores y la cantidad de procesamiento están muy por encima de la capacidad de transferencia la memoria, lo que crea un "cuello de botella"

Tipos de memoria




JERARQUÍA DE LA MEMORIA CACHE

L1, L2, L3

- L1: El nivel de Registro (Level 1).
Almacena lo que el CPU está procesando ahora mismo. Su latencia es de apenas 0.9 a 1 nanosegundo. Por lo que es muy rápido.
- L2: El Buffer Intermedio (Level 2).
Si el dato no está en L2 se busca aquí. Es un poco más lenta (de unos 2-3 nanosegundos) pero es más grande para evitar que el CPU tenga que buscar en L3.
- L3: Almacen común (Level 3).
Actúa como un "colchon" gigante. Su latencia es de unos 10-12 nanosegundos. Al ser tan grande en este caso (96MB), retiene fragmentos enormes de programas, evitando que el sistema operativo tenga que hacer viajes costosos a la memoria RAM (que tarda unos 60-70 nanosegundos).


La eficiencia de un sistema moderno no depende de la frecuencia bruta, sino de minimizar la latencia de acceso a la información.






Nivel	Ubicación	Capacidad	Velocidad
L1	Dentro de cada núcleo	64 KB por núcleo	Ultra rápida (casi instantánea)
L2	Pegada al núcleo	1 MB por núcleo	Rápida (balanceada)
L3	Compartida (Die)	96 MB (3D V - Caché)	Masiva (Evita ir a la RAM)
RAM	Fuera de la CPU	32 GB	Lenta (Causa esperas a la CPU)

STEEL NOMAD BENCHMARKS




Video

RESULTADOS



Con 3D V-Cache activado
L3 = 96MB (3D V-Cache)
L2 = 8MB
L1 = 512KB
Total = 104.5MB



Sin 3D V-Cache
L3 = 32MB
L2 = 8MB
L1 = 512KB
Total = 40.5MB

SOFTWARE BENEFICIADO

